

第四天：

上午： 本地RAG

下午： 分组交流

生成式AI的残酷真相

- 2025年，生成式人工智能（Generative AI）是最热门的词汇
 - 上半年，AI初创公司就筹集了超过440亿美元，全年总投资额预计将飙升至近2000亿美元。
- 麻省理工学院（MIT）的NANDA项目组发布了一份名为《The GenAI Divide: State of AI in Business 2025》的重磅报告
 - 尽管企业争先恐后地部署生成式AI，但高达95%的试点项目（pilot programs）都失败了，未能对公司的损益表产生任何可衡量的影响。

剖析95%的失败：四大“天坑”如何吞噬企业的AI雄心

剖析95%的失败：四大“天坑”

失败并非源于技术，而是源于企业内部的战略失误。点击下方卡片查看详情。

学习鸿沟

AI如同一个健忘的实习生，无法从特定工作流程中学习和适应。

资源错配

追逐光鲜的营销项目，而非高ROI的后台自动化。

“自研 vs. 外购”的迷思

自研项目失败率是外购的两倍，陷入DIY陷阱。

协作危机

AI无法融入人类协作体系，导致根本性的信任鸿沟。

解码5%的成功者：穿越鸿沟的四大黄金法则

- 法则一：始于微末，而后扩张 (Start Narrow, Then Scale)
- 法则二：明智外购，而非自建 (Buy, Don't Build, Wisely)
- 法则三：苛求学习，而非输出 (Demand Systems That Learn)
- 法则四：衡量关键，而非虚荣 (Measure What Matters)

“影子AI”成为真正的生产力引擎

- “影子AI”指的是员工在未经公司IT部门知晓或批准的情况下，普遍使用个人消费级AI工具（如个人版的ChatGPT、Claude等）来完成工作任务的现象。
- “地下”运动规模：虽然只有40%的公司表示为员工购买了官方的大语言模型订阅服务，但来自超过90%的受访公司的员工都报告称，他们会定期使用个人AI工具来处理工作。

AI技能不再是加分项，而是必备项

- **AI素养 (AI Literacy)**：这是一种基础能力，指的是理解AI是什么、它的工作原理、能力边界、局限性以及相关的伦理风险。
- **AI熟练度 (AI Proficiency)**：这是一种战术层面的、动手操作的能力，指的是能够在具体的工作流程中，高效、恰当地使用AI工具来达成业务目标。

一、无尽的提问

- 6W理论:
 - Know-what; Know-why
 - Know- how;
 - Know-where; Know-who; Know-when
- 实例
 - 我的名字
 - 游戏：棋类、先棋字学习
 - 打工：第一份工作。手工标注编号
 - 信息并非越多越好，接收信息的质量也很重要。
- AI也治愈了我的心病。

- 信息曾经是的，很稀缺的。所以，如果你能拿到一本书，你一定会读它，信息为没别且可其中读了。当世界，信息如此丰富。我们已被信息贪婪、因淹愤怒和恐惧，要仅进行“信息节食”。第一步我们意识到：信息并非化对如知，因越此些好。我们需同时解信息，就如此。大多数信息并非历史，因为真相有时令人不适，甚至令人痛苦。越这信果我接越多。但当方式回不是真相，真相有时令人不适，甚至令人痛苦。且往是错综复杂的，真相有时令人不适，甚至令人痛苦。

——尤瓦尔·诺亚·赫拉利

- Information was once scarce. So if you could get your hands on a book, you would read it because there was nothing else. And now information is abundant. We are flooded with information. And much of it is junk information, which is artificially full of greed and anger and fear because of this battle for attention. And it's not good for us. So we basically need to go on "an information diet". The first step is to realize that it's not the case that more information is always good for us. We need a limited amount, and we actually need more time to digest the information. And we have to be, of course, also careful about the quality of what we take in. And the basic misconception, I think, is this link between information and truth. People think: "Okay, if I get a lot of information, this is the raw material of truth. And more information will mean more knowledge." And that's not the case. Most information is not about the truth; it is to connect. And when you look at history, you see that very often, the easiest way to connect people is not with the truth, because the truth is a costly and rare kind of information. And the truth tends to be complicated, and it tends to be uncomfortable and sometimes painful.

(Yuval Noah Harari)


二、提示词元素

- 设计精良的提示词通常由任务说明、上下文、问题、输出格式四个基本元素组成：
 - 任务说明——向模型明确提出具体的任务要求。任务说明应当清晰、直接, 并尽可能详细地描述期望模型完成的任务。
 - 上下文——向模型提供的任务相关背景信息,用以增强其对任务的理解以及提供解决任务的思路。上下文可以包括特定的知识前提、目标受众的背景、 相关任务的示例,或任何有助于模型更好地理解任务的信息。
 - 问题——向模型描述用户的具体问题或需要处理的信息。这部分应直接涉及用户的查询或任务, 为模型提供一个明确的起点。问题可以是显式的提问, 也可以是隐式的陈述句, 用以表达用户的潜在疑问。
 - 输出格式——期望模型给出的回答的展示形式。这包括输出的格式, 以及任何特定的细节要求, 如简洁性或详细程度。例如, 可以指示模型以JSON格式输出结果。

AI的比喻： 超级热情但缺乏经验的实习生

- 将AI比作“**超级热情但缺乏经验的实习生**”。很多人把AI当作“专家”，希望它独立完成复杂任务。但实际上，AI态度积极，也不懂自我约束，没办法判断哪些信息关键、哪些冗余。所以，我们必须明确告知AI： **你需要什么、不需要什么，以及如何完成任务。**

LLM vs RAG vs Agents



Context Engineering（上下文工程）

- 核心理念：与其只关注“提示词”，不如先让AI充分理解任务上下文，包括任务目标、受众、写作风格、格式要求等，让它知道当前阶段和核心信息。比如这样设计提示词：
- 提示词模板：
- 你是一名[角色/身份]，任务目标是[任务目标]，受众是[目标受众]，输出风格是[xx风格]，格式要求是[格式要求]。请基于以下核心信息完成任务：[核心信息]。当前阶段是：[阶段说明]。
- 学术写作示例：
- 你是一名学术研究助理，任务目标是撰写一篇学术论文摘要，受众是国际学术期刊编辑和评审专家，写作风格要求正式、客观、简洁，格式要求为IMRAD结构（Introduction, Methods, Results, Discussion）。请基于以下信息撰写摘要：研究主题是“人工智能在医学影像诊断中的应用”，研究结果显示 AI 提高了诊断准确率 15%。当前阶段是：撰写论文摘要。

三、提示词技巧

- 掌握各种提示词技巧可以让你更好地控制模型输出:
 - 1、Few-shot Learning - 通过提供少量示例来指导模型
 - 2、Chain of Thought - 鼓励模型解释推理过程
 - 3、Reverse Prompting - 先确认关键信息，避免遗漏或胡编乱造
 - 4、Multi-persona Collaboration - 让模型扮演多个角色进行协作
- **示例：**“衍生出了一系列的扩展的方法。这些扩展的方法按照其推理方式的不同，可以归纳为三种模式：按部就班、三思后行和集思广益。”

1、Few-Shot Prompting（少样本示例）

- 核心理念：让AI通过模仿学习1-3个例子就可以显著提高输出质量。
- 提示词模板：
- 请参考以下示例的写法与风格，模仿完成新的任务。示例1：[示例文本]；示例2：[示例文本]，任务：[新的任务说明]
- 学术写作示例：
 - 请参考以下摘要示例，模仿其写作风格撰写新的摘要。示例1：“本研究探讨了深度学习在自然语言处理中的应用，结果表明模型在文本分类任务上优于传统方法。”示例2：“我们提出了一种新的数据挖掘方法，在多源异构数据集上表现出更高的准确率和可扩展性。”
- 任务：请为主题“人工智能在医学影像诊断中的应用”撰写学术摘要。

2、Chain-of-Thought（思维链推理）

- 核心理念：让AI先展示思考步骤，而不是直接给出答案，输出更有逻辑、论证完整，减少跳跃性。
- 提示词模板：
- 在给出最终答案之前，请先逐步推理你的思考过程，展示关键逻辑和推理链条，最后再总结输出。
- 学术写作示例：
- 在分析“人工智能对学术研究的影响”时，请先逐步推理：1) 目前学术研究的主要痛点是什么？2) AI工具如何分别在文献综述、数据分析和写作中发挥作用？3) 可能带来的积极影响与潜在风险有哪些？请基于上述推理，最后输出一段结构化的学术分析。

3、Reverse Prompting（反向提问）

- 核心理念：在生成内容前，让AI先提问以确认关键信息，避免遗漏或胡编乱造。
- 提示词模板：
- 在正式生成之前，请先提出你需要确认的关键信息（至少3个问题），等我回答后再进行输出。
- 学术写作示例：
- 在撰写“人工智能在医学影像诊断中的应用”学术论文引言之前，请先向我提出需要确认的关键信息（例如研究对象、研究方法、研究背景等），待我回答后再生成引言。

4、Role Assignment（角色赋能）

- 核心理念：AI输出质量取决于身份设定，明确让它“扮演专家角色”，输出内容更精准专业。
- 提示词模板：
- 你现在扮演一名[角色/身份]，请以该角色的专业角度完成以下任务：[任务说明]。
- 学术写作示例：
- 你现在扮演一名“医学影像学与人工智能交叉领域的学术专家”。请严格按照以下要求撰写论文引言：
 - 1) 专业身份：以医学影像学专家的学术视角撰写，避免模糊或泛泛的表述。
 - 2) 输出内容：必须包含以下三部分：(a) 研究背景与现状（医学影像诊断的挑战、人工智能的快速发展）；(b) 当前研究的不足（数据集有限、可解释性不足、临床落地难题）；(c) 本研究的重要性（提升诊断准确性、降低医生负担、推动智能医疗发展）；
 - 3) 写作风格：使用正式、客观、学术化的语言，避免“我们认为”“可能”等主观词汇；
 - 4) 结构要求：组织为三段式引言（背景、问题、研究意义），逻辑递进清晰；
 - 5) 受众对象：面向国际顶级医学期刊的审稿人，确保内容具备学术深度与新颖性。任务说明：请撰写主题为“人工智能在医学影像诊断中的应用”的论文引言。

四、三种思维训练

- 模拟困难对话：给AI指定目标人物性格，让它模拟对话，提高分析能力；
- 严苛批评：模拟严苛对话人，让AI提出逻辑漏洞与论证不足；
- 扩展想象力：在已有信息基础上，引导AI探索潜在创新点或新思路。

模拟困难对话

- 提示词模板：
- 请模拟一场与[目标人物]的对话，该人物具有以下性格特征：[性格设定]。在对话中，该人物将针对[讨论主题]提出质疑或挑战，你需要以学术化、逻辑清晰的方式回应。对话规则：1) 对方发言要体现[性格特点]，并提出尖锐或刁钻的问题；2) 你的回应必须基于[研究证据/学术逻辑]，避免模糊或无依据的回答；3) 对话至少持续[轮次]，逐步加深问题难度。任务目标：通过模拟对话，检验和提升论证的严谨性。
- 学术写作示例：
- 请模拟一场对话：
- 目标人物：顶级医学期刊审稿人；
- 性格设定：严格、挑剔、注重细节、追求完美；
- 讨论主题：人工智能在医学影像诊断中的应用。
- 要求：1) 审稿人需要不断质疑研究的可靠性（样本量是否足够、结果是否可重复、模型是否可解释）；2) 你需要用逻辑清晰、基于数据或文献的方式逐一回应；3) 对话至少 5 轮，最后总结研究的价值与改进方向。

严苛批评

- 提示词模板:
- 请你扮演一名严苛的[身份], 对以下[学术文本/研究摘要/论证]进行全面批评。要求: 1) 重点指出逻辑漏洞、不充分的论证、缺乏证据的地方; 2) 按照学术审稿的角度, 提出至少[数量]条具体批评意见; 3) 在批评中避免表扬或正面评价; 4) 最后总结: 若该文本投递至顶级期刊, 可能会因哪些核心问题被拒稿。待批评的文本: [在这里粘贴学术文本]。
- 学术写作示例:
- 请扮演一名顶级医学期刊的审稿人, 对以下摘要进行严苛批评: 摘要: “本研究探讨了人工智能在医学影像诊断中的应用。实验表明, 该模型的诊断准确率比传统方法提高了15%。因此, 该研究证明了人工智能在医学影像中的潜力。” 要求: 1) 提出至少 5 条严厉批评意见 (例如样本量描述不清、缺乏统计显著性说明、结论过于泛化、方法细节缺失、对比实验不足); 2) 不要给出正面反馈; 3) 总结该摘要被拒稿的最主要原因。

扩展想象力

- 提示词模板：
- 请基于以下已有信息：**[研究主题/核心结论]**，探索潜在的创新方向或新思路。要求：1) 提出至少**[数量]**个可能的研究扩展点；2) 每个扩展点需要包含“研究问题 → 潜在方法 → 可能贡献”；3) 鼓励跨学科联想，突破已有框架，但保持科学合理性；4) 输出结果需结构化呈现。目标：帮助研究者发现新的研究问题与切入点。
- 学术写作示例：
- 已有信息：研究主题为“人工智能在医学影像诊断中的应用”，现有研究主要集中在提高诊断准确率。
- 任务：请提出至少 5 个新的研究方向，每个方向需包含：
- (a) 新的研究问题（如模型可解释性、跨模态诊断、临床整合）；
- (b) 潜在研究方法（如引入可解释 AI 模型、联邦学习、跨模态融合算法）；
- (c) 预期贡献（如提高临床可接受度、保障数据隐私、提升诊断全面性）。
- 目标：帮助拓展未来研究的可能性。


训练案例

- 黄仁勋：我只用这几个AI工具：OpenAI, Gemini Pro, Claude 和 Perplexity。我几乎是同时使用这4个AI的。我会给它们同一个问题，然后让它们给出第二种看法（second opinion），它们可以互相参考彼此的答案，进一步提升结果质量。我就是这样使用它们的。我认为未来这也是一种安全机制——你会有很多不同的AI，它们之间会形成冗余、平衡和交叉验证的机制。

- AI不要想一蹶而就
 - 公众号： 《从五笔到语音》。
 - 苍穹之上的回响(陈傅晗, 2025)
- 未来，不可能是AI整个抢走工作，而是越来越多地涉及基于AI系统的配置、监控和控制。

AI Snake Oil 《AI蛇油》

Arvind Narayanan & Sayash Kapoor Princeton Univ. Press (2024)



给领导者的行动指南

跨越AI鸿沟，是一系列清醒的领导力抉择。

1. 重塑目标

停止追逐炒作，回归创造价值。将战略重心从不确定的收入增长，转移到可立刻产生回报的后台效率优化上。

2. 拥抱“影子”

将“影子AI”视为一份来自一线的战略简报，用它来识别高价值用例，并选择员工真正会使用的工具。

3. 采纳成功剧本

从小处着手，优先外购专业方案，用真实的业务成果衡量成功，而不是虚荣的指标。

4. 投资于人

将提升全员的AI素养和熟练度作为核心战略。你最持久的优势，是你的员工作为整体使用算法的能力。

“混合型角色”的崛起

- 为协作而设计工作的未来不是“人vs机器”的零和博弈，而是“人+机器”的共生协作团队。
 - 这种新的协作模式催生了全新的“混合型角色”（Hybrid Roles），例如：负责训练和验证AI模型、确保其输出质量和伦理合规性的“AI验证师”；负责优化人机交互流程的“共生流程经理”；以及从头开始设计无缝人机协作体验的“混合设计师”。

术语介绍

缩写	全称	描述
RAG	Retrieval Augmented Generation	检索增强生成
Token		模型理解和处理的基本单位
Context Window	上下文窗口	上下文窗口指的是 AI 模型在生成回答时考虑的 Token 数量。它决定了模型能够捕捉信息的范围。上下文窗口越大，模型能够考虑的信息就越多，生成的回答也就越相关和连贯。例如，GPT-4 Turbo 拥有 128k 个 Token 的上下文窗口，相当于超过 300 页的文本
Context Length	上下文长度	上下文长度是 AI 模型一次能够处理的最大 Token 数量。它决定了模型处理能力的上限。例如 ChatGPT 3.5 的上下文长度为 4096 个 Token。这意味着 ChatGPT 3.5 无法接受超过 4096 个 Token 的输入，也无法一次生成超过 4096 个 Token 的输出。
Temperature	温度	温度是控制 AI 模型生成输出随机性的参数。
Embedding	嵌入	向量化的过程。在代码库索引的上下文中，使用embeddings的目的是为了更有效地检索和排序与给定查询最相关的代码片段或文档
Ranking/Reranking		根据某种相关性或重要性度量对检索到的结果进行排序的过程，重新排序步骤提高了最终选择结果的质量，在检索速度和结果质量之间取得平衡
LLM	large language model	大语言模型
Ollama		LLM（大型语言模型）服务工具，用于简化在本地运行大语言模型，降低使用大语言模型的门槛，使得大模型的开发者、研究人员和爱好者能够在本地环境快速实验、管理和部署最新大语言模型，包括如Llama 3、Phi 3、Mistral、Gemma等开源的大型语言模型。
Lancedb		一个用于人工智能的开源矢量数据库


检索增强生成(Retrieval-augmented generation)

- 在 AI 辅助编程领域，已经有较多成熟的 AI 辅助编程插件，比如 [Copilot](#)、CodeGeex 等。通过这些插件可以实现智能聊天、代码补全、内联聊天等功能。不过随着 AI 技术发展，现有的 AI 辅助编程的准确性已经无法满足需求，如何丰富 prompt 的上下文并提升准确性，成为 AI 辅助编程的重点研究方向。在 RAG 未出现之前，通常是以编辑器内当前光标之前和之后的内容作为上下文，虽然丰富了 prompt，但是局限性也较大。比如只能获取当前文件的内容作为上下文，无法获取工程中的其它文件，一些关联性非常强的代码无法作为上下文传递给 LLM，造成 LLM 回答的准确性不足。在引入 RAG 技术后，以上问题得到了很好的解决。RAG 的原理是将本地代码进行向量化，在提问时将“用户选中代码+提问”输入到向量模型中进行查询，根据向量相似度匹配度对应代码片段，以此作为 prompt 的上下文，最后将“提问+代码+context”作为模型的输入，得到更准确的代码生成。


技术简介

- RAG 即“检索增强生成”（Retrieval Augmented Generation），这项技术通过将大量外部数据与基础模型相结合，显著增强了语言模型（LLM）的能力，使得AI的回应更加真实、个性化和可靠(Lewis 等, 2020)。
- RAG 技术的核心在于结合了检索（Retrieval）和生成（Generation）两大核心技术。在处理复杂的查询和生成任务时，RAG 首先通过检索模块从大量数据中找到与查询最相关的信息，然后生成模块会利用这些检索到的信息来构建回答或生成文本。
- 自2020年提出以来，从最初的朴素RAG（Naive Rag），到高级RAG（Advance Rag），再到模块化RAG（Modular Rag），RAG系统不断优化和迭代，以解决实际应用中遇到的问题，如索引环节中的核心知识淹没问题、**检索环节中的用户意图理解不准确问题**，以及生成环节中的冗余信息干扰问题等。

RAG 流程应用于问答的代表性实例。它主要包括 3 个步骤。1) 索引。将文档拆分成块，编码成向量，并存储在向量数据库中。2) 检索。根据语义相似性检索与问题最相关的 Top k 个块。3) 生成。将原始问题和检索到的块一起输入 LLM 以生成最终答案。



以下是 RAG 发展的几个版本:




- RAG 三种范式对比。（左）Naive RAG 主要由索引、检索和生成三部分组成。（中）Advanced RAG 围绕预检索和后检索提出了多种优化策略，流程与 Naive RAG 类似，但仍然遵循链式结构。（右）模块化 RAG 继承并发展了上一范式，整体上表现出更大的灵活性，具体表现在引入多个具体的功能模块和对已有模块的替换，整体流程不局限于顺序检索和生成，还包括迭代检索、自适应检索等方法。

- **预检索阶段。**此阶段主要关注优化索引结构和原始查询。优化索引的目标是提升被索引内容的质量。这涉及到的策略包括：增强数据粒度、优化索引结构、添加元数据、对齐优化和混合检索。而查询优化的目标是使用户的原始问题更清晰，更适合检索任务。常用方法包括查询重写、查询转换、查询扩展等技术。


- **后检索过程。**检索到相关上下文后，将其与查询有效地整合起来至关重要。后检索过程的主要方法包括重新排序块和上下文压缩。对检索到的信息重新排序，将最相关的内容重新定位到提示的边缘，这是一项关键策略。这一概念已在 LlamaIndex 2、LangChain 3 和 HayStack 等框架中实现。将所有相关文档直接输入 LLM 可能会导致信息过载，用不相关的内容稀释对关键细节的关注。为了缓解这种情况，后检索工作集中于选择必要的信息、强调关键部分和缩短要处理的上下文。

- **模块化 RAG。**它采用了多种策略来改进其组件，例如添加用于相似性搜索的搜索模块以及通过微调来优化检索器。为了应对特定挑战，引入了重组 RAG 模块和重新排列的 RAG 管道等创新。向模块化 RAG 方法的转变正在变得普遍，它支持其组件之间的顺序处理和集成的端到端训练。尽管模块化 RAG 具有独特性，但它建立在高级和简单 RAG 的基本原理之上，体现了 RAG 家族的进步和完善。

External Knowledge
Required



技术框架



RAG 技术编程领域实现原理

- Chunking
 - **文档分割**：将代码仓库中的文件或代码块按照特定大小（根据函数、类定义等逻辑单元）进行分割。目的是更精确地控制检索的粒度，同时减少检索时的噪声。
 - **保留元数据**：每个代码块需要附带其来源文件的路径、起始行号等元数据，以便于后续检索和定位。将这些元数据存储到 sqlite 数据库中。
- Embedding
 - **向量嵌入**：使用预训练的代码嵌入模型（如CodeBERT、GraphCodeBERT等）将分割后的代码块转换为向量表示。
 - **建立索引**：使用向量数据库（如 Faiss、Annoy 等）存储代码块的向量。这里使用专用的 lance 数据库，用于后续的相似度计算和检索。
- Query
 - **查询构建**：用户输入查询时，可以是基于关键字、代码片段、功能描述等的查询。
 - **查询转换**：使用查询重写、查询扩展等技术，让用户输入的查询转换为更精确、适合检索的格式。
- Retrieval
 - 使用用户提交的查询，在索引库中进行检索，找到与查询最相关的文档块。
 - 这通常涉及计算查询向量与索引库中所有向量之间的相似度。
- Reranking
 - 对检索到的文档块进行重排，以进一步提高结果的准确性。
 - 这可能基于多种因素，如相关性、多样性、权威性等。
- Combine Query
 - 将检索到 Chunks 和用户的 Query 作为 LLM 的输入，形成更丰富的 Prompt。
- Generation
 - 使用大型语言模型（LLM）根据检索到的信息生成响应或答案。

https://tiktokenizer.f2api.com/

←

→

↺

tiktokenizer.f2api.com

🔍

👤 问

Tiktokenizer

System

You are a helpful assistant

×

User

管理学

×

Add message

```
<|im_start|>system
You are a helpful assistant<|im_end|>
<|im_start|>user
管理学<|im_end|>
<|im_start|>assistant
```

```
<|im_start|>system
You are a helpful assistant<|im_end|>
<|im_start|>user
管理学<|im_end|>
<|im_start|>assistant
```

Token count


20

Price per prompt

\$0.00002

```
[100264, 9125, 198, 2675, 527, 264, 11190, 18328, 100265, 1
98, 100264, 882, 198, 40452, 48864, 100265, 198, 100264, 78
191, 198]
```

文档解析神器——MinerU: <https://mineru.net/>



LLM训练数据集的选择与清洗：从Common Crawl到高质量语料库

- 大语言模型需要利用数以万亿计的文本数据进行训练，其中最常用的数据来源之一是Common Crawl通用网络爬虫数据集。这个海量数据集包含约2500亿个网页，总容量达数TB。然而，网络数据质量参差不齐，无法直接用于训练。“网页中大量充斥着无关的HTML代码，而非有效内容”，因此数据清洗至关重要，需要提取有价值的内容，如正文段落、标题和文本，同时过滤掉无用的HTML标签。
- 数据集清洗还需要处理多个关键问题：首先，移除有害内容，如带有偏见或煽动仇恨的言论；其次，剔除虚假信息；再次，去除重复内容，因为“同样的书籍、期刊和文章常常在多个网站上重复出现”，清理这些重复内容能确保数据多样性；最后，过滤掉随机无意义且语法混乱的文本和质量较差的社交媒体俚语评论，因为这些内容“不适合训练大语言模型”。
- 收集各个领域的多样化数据至关重要，这样模型才能学习到完整的语言知识体系。经过这些处理步骤，最终得到的高质量数据集被称为“语料库”(corpus)，是训练大语言模型的基础。

分词挑战：词级与字符级的权衡

- 分词(tokenization)是将文本转换为模型可处理的基本单位的过程。最简单的方法是基于空格将文本分割成单词级别的词元(tokens)。但这种方法面临"词表外标记"(out-of-vocabulary tokens)问题：当遇到训练数据中未出现过的词时，模型无法处理。例如，如果词表中没有"is"和"sleeping"这两个词，使用词级分词时就会出现无法识别的情况。
- 解决词表外问题的一种方法是采用字符级分词，即"不是将整个单词作为一个标记，而是为每个字符单独分配标记"。这种方法虽然解决了词表外问题，但也带来了新的挑战：首先，单个字符缺乏上下文语义；其次，字符级分词会产生更长的标记序列，显著增加计算负担。例如，"how are you"这个短语，用词级分词只需3个标记，而用字符级则需要11个，"这样会大大加大语言模型的计算负担"。
- 这两种方法各有优缺点。词级分词能更好地捕捉词义，适合语言模型训练，但存在未登录词问题和词表规模较大的缺点。字符级分词的优点是词表规模小且没有未登录词问题，但缺点是序列长度增加、缺乏上下文含义，不适合语言模型训练。综合这些考虑，研究人员提出了多种解决方案，而GPT模型选择了字节对编码技术。

字节对编码： GPT模型的分词选择

- 字节对编码(Byte Pair Encoding, BPE)技术最早可追溯到1994年，由 Philip Gage 首次提出，后来被研究者微调应用于深度学习模型。这种编码技术在词表规模和文本长度之间取得了平衡，不使用单个字符，也不会将整个词作为词元，而是采用子词(subwords)作为基本单位。
- BPE的工作原理是合并高频字节对或字符序列。例如，如果用"low"、"lowest"、"newer"和"wider"这几个词训练分词器，然后尝试编码"lower"这个词（它并不在训练数据中），BPE会将其分解为"low"和"er"两个子词，因为这些子词在训练数据中频繁出现。这样，我们得到两个词元，它们分别是子词'low'和'er'，这些子词在训练数据中经常出现。
- 字节对编码有效控制了词表大小和序列长度，在GPT等大型语言模型中得到广泛应用。"BPE本质上是一个分词器，需要在LLM训练前单独进行训练"。它将文本切分为子词单元，每个子词都对应一个唯一的整数词元编号。

对话格式与特殊标记的应用

- 在大语言模型的微调过程中，数据集需要整理成特定格式，包含 System、User、Assistant 等特殊标记。"GPT-4 采用特定的提示词模板，用这些特殊标记来界定文本的起始、分隔点和结束位置"。这些被称为特殊标记，因为它们在模型微调时会被保留，分词器会直接将这此标记映射为对应数值，而不会像处理普通词元那样尝试拆分。
- 这些特殊标记在大模型训练中扮演着重要角色，它们用于规范文本格式，将内容整理成对话形式，帮助模型理解文本结构。在实际应用中，这些标记帮助模型区分输入文本的不同部分，增强了模型处理对话和指令的能力。

训练数据准备：上下文窗口与标签错位

- 在准备大语言模型的训练数据时，需要考虑上下文窗口大小和标签设置。例如，假设有一个包含60个词元的训练数据集，模型的上下文长度设为10个词元，意味着每个训练样本中模型一次处理10个词元的文本。
- 训练标签与训练文本内容一致，但整体向右移动一个标记位置，"这样，模型就能学会根据上下文预测下一个标记"。这种方式确保在训练的每个步骤中，模型都能基于已知上下文学习预测对应的目标输出，同时保持最大上下文长度为预设值。
- "训练数据和标签之间会错开一个单位"，这是自回归语言模型训练的核心机制，使模型能够学习预测序列中的下一个元素。虽然这个概念在没有了解注意力机制和损失函数计算方法时可能不太容易理解，但它是大语言模型训练的基础设计。

GPT系列模型的数据规模演进

- 根据OpenAI发表的论文，GPT-2模型的训练数据来自约800万个网页，相当于80GB的数据。该模型使用了50,257个词元的词表，采用字节对编码(BPE)，上下文长度设为1,024个词元，训练批次大小为512。
- 而规模更大的GPT-3模型，拥有1750亿参数，训练采用了2048词元的上下文窗口。其训练数据主要来自通用网络爬虫数据集(Common Crawl)，经过数据去重和高质量筛选，通过字节对编码处理后，最终得到约4000亿个训练词元。"GPT-3是一个拥有1750亿参数的自回归语言模型"，其数据规模和模型参数数量都远超GPT-2，展示了大语言模型快速发展的趋势。
- 这些数据显示，随着模型规模的增长，训练数据量、上下文窗口大小和词表规模也相应增加，以支持更复杂的语言理解和生成能力。GPT系列模型的演进清晰地展示了大语言模型在数据规模和模型复杂度方面的快速发展。

数据准备与分词处理结论

- 大语言模型训练的第一步——数据准备与分词处理，为整个训练过程奠定了坚实基础。高质量、多样化的数据集是训练成功的前提，而合适的分词技术则直接影响模型的理解能力和计算效率。通过字节对编码等先进分词方法，大语言模型能够有效平衡词表大小和序列长度，解决传统分词方法面临的词表外问题。
- 随着GPT等模型的发展，训练数据集规模从几十GB扩展到数百GB，词元数量从数十亿增长到数千亿，展示了大语言模型对海量训练数据的需求。未来，随着更高效的数据处理技术和更先进的分词算法出现，大语言模型的性能有望进一步提升。
- 之后继续深入探讨词嵌入技术，这是将分词后的标记转换为数值表示的关键步骤，帮助模型理解词元的含义。数据准备、分词处理和词嵌入共同构成了大语言模型训练的基础环节，为后续的模型架构和训练过程提供了必要支持。

机器学习中的文本数据转换基础

- 机器学习的第一条黄金法则是将输入数据转换成数字形式。对于图像来说，像素值自然构成了数值表示，但对于文本数据，这一转换过程则相对复杂。最简单的做法是给每个词分配一个唯一的数字编号，这也是分词处理中的常见做法。
- "机器学习建模的第一步就是把输入数据转换成数字。"讲者解释了这一基本原则，并指出对于文本数据，最直接的做法是"给每个不同的词都分配一个对应的数字"。然而，这种方法存在严重缺陷，因为数字间的关系可能误导模型理解词语间的语义关系。例如，如果"好"被赋值为6，"坏"被赋值为22，"极好"被赋值为21，模型可能错误地认为"坏"和"极好"由于数值接近而含义相近，而实际上"好"和"极好"的含义才更接近。
- 这种表征方式的局限性意味着简单的数字编号不适合作为机器学习模型的输入特征，需要更复杂的表示方法来捕捉词语之间的语义关系。

独热编码：解决数值排序问题的方法

- 为了解决简单数字编号带来的排序问题，独热编码(One-hot encoding)提供了一种替代方案。在这种方法中，每个词都用一个向量表示，向量长度等于词表大小，其中只有一个位置是1（表示该词存在），其他位置都是0。
- "在独热编码中，每个词都对应一个独特向量，向量维度等于词表大小。这种方法可以解决排序问题，也就是词元编号的问题，同时保证所有词都是平等的，它们之间没有任何隐含的数值关系。"
- 独热编码有效地消除了数值之间的意外关联，实现简单，但同样存在明显缺点：如果词表包含5万个单词，每个词需要用5万维的稀疏向量表示，不仅占用大量内存，计算成本也相当高。更重要的是，独热编码完全忽略了词语的语义和上下文信息，无法表达词语之间的关联，如"好"和"极好"这样含义相近的词在表示上毫无关联。
- 这些局限性导致独热编码在处理大规模自然语言任务时效率低下，需要更高级的表示方法。

词袋模型与n元语法：添加上下文信息

- 词袋模型是另一种常见的文本表示方法，它统计每个词在句子中出现的频率，然后将这些频次填入对应词语的位置。由于只考虑单个词的出现频率，这种方法也被称为一元语法(unigram)模型。
- "这种方法的原理是统计每个词在句子中的出现频率，然后将统计到的频次填入对应词语的位置。这种方法只考虑单词频次，因此也被称为一元语法模型，因为它将每个词都作为独立单位来处理。"
- 为了添加更多上下文信息，我们可以扩展到二元语法(bigram)，即考虑两个词的组合，统计所有可能的两词组合出现的频率。更广泛地，可以使用n元语法(n-gram)特征，捕捉最多n个相邻词之间的关联。
- 然而，n元语法作为特征也面临几个挑战：在大型数据集中，可能的n元组合数量庞大，导致特征向量变得极其稀疏；模型每次只能考虑有限数量的词（如三词的组只能捕捉三个词的上下文）；此外，n元语法无法理解词语之间更深层的语义和联系，因此在机器翻译和文本生成等依赖深度语义理解的任务中效果有限。

词嵌入：捕捉词语语义的密集向量表示

- 词嵌入是自然语言处理中的关键技术，它将词语映射到连续的向量空间中，形成密集数值向量表示。与独热编码不同，词嵌入的向量是密集的，且向量之间的关系能够反映词语之间的语义关系。
- 词嵌入通常使用几百到几千维的向量表示词语，远低于独热编码所需的维度，同时又能保留词语的语义信息，使得模型能够理解词语之间的关系。

Word2Vec: 训练词嵌入的经典方法

- Word2Vec是谷歌开发的一种训练词嵌入的经典方法，能够在向量空间中高效地计算词的表示。Word2Vec主要包括两种训练技术：连续词袋模型(CBOW)和跳字模型(Skip-gram)。
- 连续词袋模型(CBOW)的训练过程是这样的：首先设定一个窗口大小（如窗口大小为3，表示上下文长度为1），窗口中心的词是目标词，周围的词作为上下文信息。通过让模型学习从上下文词预测中心词的任务，训练得到词嵌入。
- 跳字模型(Skip-gram)与CBOW模型恰好相反：它使用中心词作为上下文，去预测周围的词。尽管两种方法有所不同，但它们在训练词嵌入方面都很有效。
- 训练完成后，嵌入矩阵就像一个查找表，每个词都能在其中找到对应的唯一向量的表示。这些向量包含了词语的语义信息，使得模型能够理解词语之间的关系。

Transformer中的词嵌入机制

- Transformer架构，尤其是其解码器部分，对词嵌入的使用有所不同。在文本生成模型中，词嵌入是通过一个专门设计的嵌入层实现的。
- 解码器的目标是预测下一个词元，因此嵌入层输出词的向量表示后，这些向量会经过多层解码器处理，最终通过输出层预测下一个词元。输出层同样是一个线性层，但与嵌入层不同的是，"输出层的神经元数量等同于词表的总大小"，这样模型就能为每个可能的后续词元分配概率。
- 整个过程中，模型先将词元映射到嵌入空间，然后利用这种表示来预测下一个词元。这与Word2Vec利用上下文词预测目标词的方式有所不同，大语言模型的目标是根据已有词语预测下一个词，并且在生成下一个词元前，需要经过多层解码器对词嵌入进行处理。

位置编码：添加序列信息


- 位置编码使得Transformer模型能够理解词元在序列中的位置，这对于正确理解语言至关重要。加入位置信息后，嵌入矩阵就可以送入注意力机制进行处理，这是解码器的第一层，也是大型语言模型的核心部分。
- 与RNN需要逐个处理词元不同，Transformer架构能够并行处理所有词元。但这也意味着模型无法自然地了解词元的位置信息，即哪个词在前，哪个词在后。

结论：词嵌入在自然语言处理中的关键作用


- 从简单的数字编号和独热编码，到词袋模型和n元语法，再到Word2Vec和Transformer中的自定义嵌入，文本表示方法不断演进，越来越能够捕捉语言的复杂性。特别是在Transformer架构中，词嵌入与位置编码相结合，为注意力机制提供了富含语义和位置信息的输入，这是大语言模型强大能力的基础。
- 随着自然语言处理技术的不断发展，词嵌入方法可能会继续改进，以捕捉更细微的语言特征。然而，词嵌入的基本思想——用密集向量表示词语的语义——仍将是未来NLP技术发展的核心。正如视频中所说，“注意力机制是大型语言模型的核心”，而词嵌入则是这个核心机制的基础。通过更好地理解和改进词嵌入技术，我们可以期待自然语言处理在未来取得更大的突破。

知识库AI——ima.copilot

<https://ima.qq.com/>



知识库：从Zotero整体添加（Moov Add-on）



© Academy of Management Review
1994, Vol. 19, No. 1, 11–16.

1993 Presidential Address:

WHAT IF THE ACADEMY ACTUALLY MATTERED?

DONALD C. HAMBRICK
Columbia University

AI解读

翻译

记笔记

复制

the Academy of Management and the whole thing goes belly-up.”

Actually, it was not as crushing an article as its title implied. It was mainly a **rehash** of the obvious and well-worn point that someone who succeeds in managing one enterprise will not necessarily do well in another one—that you can’t just parachute in and analyze your way out of any complex managerial dilemma. As if someone said you could, One more straw man skewered. **Namely**, the article did not exactly deal a fatal blow to our field or its premises.

So, as Mark Twain said, news of our death is greatly exaggerated. But it gets one thinking. What if the field of management, or say, specifically the Academy of Management, did die? Which, in turn, gets one thinking, What if the Academy of Management never existed? What if we had no occasion to be here in this room today?

To think in these terms is to conjure up Frank Capra’s film classic, *It’s A Wonderful Life*. In the movie, Jimmy Stewart plays George Bailey, the small-town banker who attempts to end his own life, only to be shown the error of his ways by his guardian angel named Clarence. Clarence’s tactic, of course, is to take George Bailey back through time and show him the void that would have occurred if there had been no George Bailey, reminding him of all the lives he’s touched and people he’s helped—how the world is much better off because he’s here.

Let me be your guardian angel for a few moments, giving you a glimpse of what might have been if there were no Academy of Management. It will be an unsettling trip. Unlike George Bailey, we will find that things might have worked out very, very well without us. Frankly, I’m not

I am indebted to the following individuals for helpful discussions about the matters raised in this address and suggestions on earlier drafts: Richard Bettis, James Fredrickson, David Jemison, Ian MacMillan, Greg Oldham, Michael Tushman, and John Veiga.

11

《管理学会评论》1994年，第19卷，第1期，11-16页。

1993年总统演讲：

如果学术真的那么重要呢？

唐纳德·C·汉布里克 哥伦比亚大学

今年春天，《新闻周刊》刊登了一篇标题惊人的文章，题为“管理的终结”（萨缪尔森，1993年）。看到这篇文章时，我暗自叹气：“真倒霉啊。我担任管理学会会长的这一年，一切都搞砸了。”

其实，这篇文章并不像其标题所暗示的那样具有毁灭性。它只不过是在重复一个显而易见的事实：一个在管理某家企业时取得成功的人未必能在另一家企业中同样表现出色——也就是说，你无法仅凭分析就解决任何复杂的管理难题。仿佛有人认为分析就能解决问题似的。这篇文章其实并没有对我们所在领域或其基本理念造成致命打击。

正如马克·吐温所说，关于我们“死亡”的传闻被大大夸大了。但这引发人们思考：如果管理学领域，或者更具体地说，管理学院真的消失了会怎样？进一步想的话，如果管理学院从来就不存在过呢？如果我们今天根本没有机会来到这个房间里会怎么样？

以这样的视角来思考，就会让人联想到弗兰克·卡普拉的经典电影《生活多美好》。在影片中，吉米·斯图尔特饰演乔治·贝利——这位小镇银行家试图结束自己的生命。然而，他的守护天使克拉伦斯让他意识到自己的错误。克拉伦斯的办法是带乔治回到过去，让他看到如果没有乔治·贝利这个世界将会陷入怎样的混乱。由此，乔治明白了自己影响过多少人的生活、帮助过多少人；他也意识到，正因为有他的存在，世界才变得更加美好。

让我暂时充当你的守护天使，让你了解一下如果没有“管理学院”会是什么样子。那将是一段令人不安的体验。与乔治·贝利不同，我们会发现没有我们，事情反而可能会发展得非常好。坦白说，我并不这么认为。

对于在本文中提及的议题以及早期草稿所收到的宝贵建议，我衷心感谢以下各位人士的帮助与指导：理查德·贝蒂斯、詹姆斯·弗雷德里克森、大卫·杰米森、伊恩·麦克米兰、格雷格·奥尔德里姆、迈克尔·塔什曼以及约翰·维加。

11

生成播客

ima

1994_Hambrick
8分41秒

DS V3.2

@

内容由AI生成仅供参考

0Book

8项


My Library.csv

EXCEL

ation management

25/12/17更新

- 来源:《2000_Lewis.pdf》
- 描述: 该图展示了悖论的基本框架。图中包含“张力 (Tensions)”、“强化循环 (Reinforcing cycles)”和“管理循环 (Management cycles)”等要素, 并指出悖论在认知或社会建构上会形成“掩盖矛盾相互关联性的两极对立 (polarities)”, 例如自我指涉循环、混合信息和系统矛盾等。该图旨在说明悖论如何产生以及管理循环如何应对这些张力。



2. 管理战略矛盾的悖论认知模型图 (Figure 2)

来源:《2005_Smith and Taskiran.pdf》

基于当前文件夹提问

对话模式

DS V3.2

AI-Butler: 文献自动全文解读 (Deepseek, 185元看完我的4500篇)

The screenshot displays the AI-Butler interface, which is a web-based tool for managing and interpreting academic literature. The interface is divided into several sections:

- Top Bar:** Includes a search bar with the text "Artificial intelligence" and a menu with options like File, Edit, View, Tools, and Help.
- Left Sidebar:** A navigation menu titled "my Library" with a tree structure of folders. The "Artificial int..." folder is currently selected.
- Central List:** A list of document titles. The selected item is "AI 管家 - AI and IoT-based collaborative business ecosystem: a case in Chinese fish farming industry", which is highlighted in blue. Other visible titles include "A contingency theory of representational comple...", "A design-thinking perspective on capability devel...", "A model of (often mixed) stereotype content: co...", "A pragmatic view of knowledge and boundaries: ...", "A systematic approach to conducting review stud...", "A theory of fairness, competition, and cooperation", "1999_Fehr and Schmidt.pdf", "2020_Yang et al..pdf", "AI on drugs: can artificial intelligence accelerate ...", "An intellectual history of institutional theory: look...", "An investigation into the determinants of custom...", "Artificial intelligence (AI): multidisciplinary pers...", "Artificial intelligence and business value: a literat...", and "Artificial intelligence and entrepreneurship: impli..."
- Right Panel:** A detailed view of the selected document. It shows the title "AI 管家 - AI and IoT-based collaborative business ecosystem: a case in Chinese fish farming industry" and a summary in Chinese: "这篇论文的核心内容是通过对中国智慧渔业企业“鲈鱼科技” (Celeyfish) 的案例研究, 展示了人工智能 (AI) 与物联网 (IoT) 如何构建并驱动一个协同商业生态系统 (Collaborative Business Ecosystem, CBE)。该研究详细阐述了鲈鱼科技如何作为核心企业, 利用A-I技术搭建数字化平台, 整合鱼农、饲料供应商、金融机构、保险公司、分销商及政府等多方参与者, 通过数据共享与流程协同, 实现成本控制、风险最小化、水质污染防治及渔业质量提升等多维度的价值共创。研究进一步论证了这种A-I赋能的CBE不仅解决". Below the summary, it shows "1 Tag" (AI-Generated) and "0 Related" items.

AI时代重要工具：数字笔记（Markdown）

扣子AI基本原理

全部

AI与知识库部署模式矩阵
星期二 AI与知识库部署模式矩阵：本地与云端的组合策略 基于您提供的搜索...


根据搜索结果，国内确实存在多个类似Op...
1/17 一、国内类似OpenRouter的主流平台概览 这些平台通常提供统一的API接口（兼容OpenAI格...
过去30天

扣子AI基本原理
1/14 类似“扣子”（Coze）这样的AI应用开发平台，其基本原理可以概括为：一个通过低代码/零代码方...
提示词技巧
1/12 好的，我将为您系统性解读“提示词技巧”。基于对多篇专业文章的综合分析，提示词技巧远非...
西蒙贡献
1/12 根据您的文档内容，特别是赫伯特·西蒙（Herbert A. Simon）关于do...


AI工具个人使用经验
1/12 根据您的描述，从Zotero到Cherry Studio再到jima.copilot的学习和使用路径，这实际上是一条从专...
Econometrics AI Agent
1/9 资源汇总 论文来源：<https://arxiv.org/abs/2506.00856> Git Hub：<https://github.com/FromCSUZhong>
分步骤的工具有哪些
1/5 根据搜索结果，构建RAG系统通常需要组合使用多种工具，覆盖从数据处理、向量化、检索到生成...
人工智能

扣子AI基本原理 × +

目录

2. 技术本质：AI加持的低代码业务编排平台
从技术演进角度看，这类平台并非凭空出现。它本质上是**生成式AI（GenAI）时代的一种新型低代码/零代码（LCNC）业务编排平台**。其技术基因继承并发展了前AI时代的集成平台（如IFTTT）和企业服务总线（ESB）的思想，但关键突破在于：

- **自然语言作为交互与配置界面：**用户不仅可以通过自然语言与最终生成的AI应用交互，甚至在开发阶段也能用自然语言描述需求，由平台自动生成智能体的基础框架或 workflow 节点，极大降低了配置门槛。
- **大模型作为通用处理节点：**在工作流中，大模型不再仅仅是聊天接口，而是成为一个强大的通用处理器，可以灵活承担意图识别、内容摘要、格式转换、决策判断等多种角色，使得流程编排的灵活性和智能化程度大幅提升。

3. 关键能力：连接、理解与执行
综合来看，此类平台的基本原理围绕三个关键能力展开：

- **连接万物：**通过插件体系和工作流，平台能够无缝连接数字世界的各种服务（如社交媒体、企业系统），甚至通过物联网（IoT）插件连接物理世界的设备（如查询传感器数据），成为虚拟与现实的智能接口。
- **理解意图：**依托底层大语言模型的语义理解能力，平台能够将用户模糊的自然语言指令，精准转化为明确的可行任务序列。
- **执行闭环：**通过将“理解-规划-调用-生成”的环节固化在工作流中，平台能确保复杂任务被稳定、可靠地执行，形成完整的输入-输出闭环，而不仅仅是进行单轮对话。

总结：类似扣子的AI平台，其基本原理是**构建了一个以可视化编排为手段、以AI智能体为交付形式、以连接和增强各类能力为目标的“AI应用工厂”**。它通过模块化封装大模型、工具、数据等核心要素，让开发者能够像搭积木一样，快速组装出适应各种场景（如智能客服、知识问答、办公自动化、物联网控制）的AI应用，从而极大地加速了AI技术的普惠和落地进程。

👤 AI帮写 📄 配图 🌐 翻译 ✎ AI解读

AI与知识库部署模式矩阵

AI与知识库部署战略选择

在安全、成本与效率间寻求最佳平衡

完全私有化部署

混合架构

完全云端化部署



- 数据敏感性极高
- 完全内控控制
- 初始成本高



- 平衡安全与效率
- 灵活适应变化
- 技术要求复杂



- 业务快速扩展
- 技术门槛较低
- 按需付费

AI部署方式	本地知识库	云端知识库
本地AI模型	完全私有化部署 • 数据安全最高级：所有数据都在内网流转，100%满足金融、医疗、政务等强监管行业的合规要求 • 成本结构：前期硬件投入高（如GPU集群），但长期高频使用下单位成本低 • 技术门槛：需要专业团队负责模型部署、优化和运维 • 响应速度：毫秒级延迟，不受网络波动影响 • 定制化能力：可深度微调模型、优化检索逻辑，适配专属业务场景	混合架构（数据本地+AI云端） • 安全与成本平衡：核心敏感数据留在本地，非敏感业务调用云端AI能力 • 适用场景：适合需要深度定制但部分数据可上云的企业 • 集成复杂度：需协调本地与云端的数据同步与权限管理 • 典型应用：政务、金融等行业的“数据本地+算力云端”模式
云端AI服务	混合架构（数据云端+AI本地） • 数据风险可控：知识库在云端便于协作，但AI处理在本地保障核心算法安全 • 协作优势：支持多用户实时访问和编辑，适合跨团队知识管理 • 成本特点：按存储和协作功能付费，AI推理成本固定 • 更新维护：知识库内容可实时更新，但AI模型更新需手动部署	完全云端化 • 部署速度最快：开箱即用，几分钟即可接入服务 • 成本模式：按API调用次数或订阅付费，适合低频使用场景 • 数据风险：用户数据需上传至第三方服务器，存在合规风险 • 技术迭代：自动享受最新模型能力，无需手动更新 • 弹性扩展：云服务商自动分配算力，轻松应对流量波动

生成播客： Hambrick D C, 1994. What if the academy actually mattered?[J]. Academy of Management Review, 19(1): 11-16.

